Rapport de tests E2E — Traduction en direct multisession

Oct 5, 2026 · @manel

Synthèse générale des tests E2E

Verdict : le multisession fonctionne, mais l'application n'est pas prête pour un événement en direct sur cette machine. L'isolation des sessions, leur cycle de vie, l'isolation des pannes et les parcours utilisateurs fonctionnent. L'usage en direct est bloqué par le retard des sous-titres, et un défaut critique peut faire disparaître des traductions sans avertissement.

- **27 fonctionnalités réussies, 6 échouées, 9 non testées ou bloquées.** Sur 9 exécutions à plusieurs salles, aucun mot-clé d'une autre conférence n'est arrivé dans une salle, et chaque écran public a reçu exactement les mêmes sous-titres que sa régie.
- **Critique :** quand deux modèles Marian ou plus se chargent en même temps (par exemple, plusieurs salles qui démarrent ensemble), le chargement peut échouer avec `Cannot copy out of meta tensor`. Ensuite, **tout nouveau chargement de modèle échoue dans le processus du serveur**, et les paires de langues touchées ne sont plus traduites jusqu'au redémarrage du serveur. C'est arrivé sur 2 des 6 démarrages du serveur, et le problème a été reproduit hors de l'application lors de 2 essais sur 3.
- **Élevé :** avec la configuration réelle, Whisper `large-v3-turbo` est passé sur CPU, faute des bibliothèques CUDA 12. Les sous-titres arrivent alors avec un retard médian de **23 s avec 1 salle et 54 s avec 3 salles**. Whisper `small` ramène ce retard à 16 s pour 3 salles, ce qui n'est toujours pas du temps réel.
- **Moyen :** une seule trame audio invalide (nombre d'octets impair) ferme la connexion de la régie et met fin à sa session, sans aucun message.
- Problèmes mineurs : la régie ne se reconnecte pas seule après une coupure du serveur, la tuile « Retard des mots » sous-estime le retard réel, et l'écran public masque le message de panne.

La transcription sur GPU n'a pas pu être testée : les bibliothèques CUDA manquent, et un autre programme occupait la plus grande partie des 4 Go de VRAM.

Matrice des résultats

27 fonctionnalités réussies, 6 échouées et 9 non testées ou bloquées. Les identifiants de scénarios renvoient aux sections suivantes.

#	Fonctionnalité	Scénarios	Résultat	Preuve principale
1	Démarrer une session depuis la régie	S1, UI-2	RÉUSSI	`created → starting → running` en moins de 1 s
2	Arrêter une session (l'audio restant est quand même traduit)	S1, S4	RÉUSSI	`stopping → stopped`, toutes les phrases traduites, test enregistré
3	Redémarrer une session dans la même salle	S1, S4, S5	RÉUSSI	Second passage complet, WER de 0 à 6,2 %
4	1 session	S1	RÉUSSI	WER 5,7 % (allemand), 0 % (français)
5	2 sessions simultanées	S2	RÉUSSI	Les deux complètes, aucune fuite
6	3 sessions simultanées	S3	RÉUSSI	Les 3 complètes, aucune fuite
7	4e session refusée quand 3 tournent	S3	RÉUSSI	Message clair « Capacité atteinte » qui nomme les 3 salles occupées
8	Des participants rejoignent et quittent une salle	S2, S3	RÉUSSI	Liste des participants de `/api/rooms` mise à jour en moins de 0,5 s
9	Un spectateur qui arrive en retard voit les sous-titres récents	UI-4	RÉUSSI	Changer de salle affiche les derniers sous-titres de cette salle
10	Chaîne complète : audio → Whisper → SaT → Marian → sous-titres	S1–S3	RÉUSSI	Traductions EN/DE/FR correctes, WER de 0 à 7,7 %
11	Sous-titres et traductions n'arrivent que dans leur session	S2–S5, UI	RÉUSSI	Aucun mot-clé d'une autre conférence sur 9 exécutions à plusieurs salles
12	Les spectateurs reçoivent exactement ce que reçoit la régie (diffusion)	S2, S3	RÉUSSI	Phrases et traductions définitives identiques
13	Panne d'une session, les autres continuent	S5, UI-6	RÉUSSI	Salle A → `error` ; B et C vont au bout
14	Place libérée réutilisée pendant qu'une salle est en erreur	S5	RÉUSSI	Salle D démarrée pendant l'erreur de A

#	Fonctionnalité	Scénarios	Résultat	Preuve principale
15	Redémarrage après une panne	S5	RÉUSSI	A redémarrée et terminée, WER 5,7 %
16	Voix du navigateur (TTS)	S1–S3, UI-2, UI-3	RÉUSSI	`speechSynthesis.speak` appelé une fois par phrase définitive, dans la bonne langue
17	Voix Piper (TTS), 3 salles	TTS-P3	RÉUSSI	18 WAV valides, 0,1 à 0,4 s par phrase
18	Voix Piper absente signalée	TTS-P2	RÉUSSI	Erreur claire avec la commande de téléchargement ; traductions non affectées
19	Alias WebSocket `/ws/session/{id}`	S6	RÉUSSI	Régie et spectateur fonctionnent
20	Seconde régie sur une salle occupée refusée	S6, UI-5	RÉUSSI	Message d'erreur, bouton Démarrer désactivé
21	Commande JSON invalide	S6	RÉUSSI	Erreur renvoyée, connexion maintenue
22	Déconnexion brutale de la régie	S6	RÉUSSI	Place libérée et état `stopped` en moins de 3 s ; le spectateur reste connecté
23	La régie se reconnecte à la même salle	S6	RÉUSSI	Acceptée, nouvelle session possible
24	L'écran public se reconnecte après un redémarrage du serveur	UI-8	RÉUSSI	Reconnecté environ 4 s après le retour du serveur
25	Changement en direct des langues et de la politique de coupe	S6	RÉUSSI	Nouvelles langues appliquées aux phrases suivantes
26	Tableau de bord : états, capacité, suppression d'une salle	UI-1, UI-6, UI-7	RÉUSSI	États affichés en temps réel ; suppression en deux clics
27	Interface de la régie : mode fichier, mode micro, boutons	UI-2, UI-3	RÉUSSI	Les deux modes fonctionnent ; voir la remarque sur la ponctuation en mode micro dans Problèmes
28	Sous-titres en temps réel avec la configuration réelle	S1–S3	ÉCHOUÉ	Retard médian de 23 s (1 salle) à 54 s (3 salles)

#	Fonctionnalité	Scénarios	Résultat	Preuve principale
29	Chargement simultané de modèles Marian	TTS-P1, essai beam 1, reproduction	ÉCHOUÉ	Tous les chargements suivants échouent ; des paires perdent leurs traductions sans avertissement
30	Résistance à une trame audio invalide	S6	ÉCHOUÉ	Connexion fermée, session terminée, aucun message
31	La régie se reconnecte après une coupure du serveur	UI-8	ÉCHOUÉ	Il faut recharger la page à la main
32	L'écran public affiche une panne de session	UI-6	ÉCHOUÉ	Affiche « Session terminée » au lieu d'une interruption
33	Indicateurs de retard de la régie	UI-2	ÉCHOUÉ	« Retard des mots » affiche 1,9 s pour 22 s mesurées ; la tuile indique GPU alors que Whisper tourne sur CPU
34	Whisper sur GPU	—	Non testé / bloqué	Bloqué : bibliothèques CUDA 12 absentes, VRAM occupée par un autre programme
35	Vrai micro ; régie sur un autre ordinateur (HTTPS)	—	Non testé / bloqué	Seul un micro simulé a servi
36	Plusieurs micros dans une salle (mode panel)	—	Non testé / bloqué	Non testé
37	Campagne de tests et analyse automatique	—	Non testé / bloqué	Non testé
38	Unités de sens	—	Non testé / bloqué	Non testé
39	Test d'endurance (plusieurs heures), croissance de la mémoire	—	Non testé / bloqué	Environ 1 heure de sessions seulement
40	Démarrage avant la fin du chargement des modèles	—	Non testé / bloqué	Non testé
41	Nombreux spectateurs par salle (par exemple 100 téléphones)	—	Non testé / bloqué	2 spectateurs par salle au maximum
42	Boutons de taille du texte de l'écran public	—	Non testé / bloqué	Non testé

Environnement et configuration de test

Tous les tests ont utilisé le vrai code de l'application, le vrai `config.yaml` et les vrais modèles (aucune simulation), sur un seul poste Windows.

Élément	Valeur
Système	Windows 10 Pro 10.0.19045
Processeur	Intel Core i7-12650H, 10 cœurs / 16 threads
Mémoire	34 Go
GPU	NVIDIA GeForce RTX 2050, 4 Go de VRAM, pilote 610.78. 2,6 à 3,7 Go étaient occupés par un autre programme (`whisper_service.py` , PID 3640), laissé en marche, comme demandé
Python	3.10.0 (interpréteur du système)
Paquets principaux	fastapi 0.142.2, uvicorn 0.54.0, faster-whisper 1.2.1, ctranslate2 4.8.2, wtpsplit 2.2.2, onnxruntime 1.23.2, torch 2.9.1+cpu, transformers 5.8.0, piper-tts 1.8.0
Outils de test	Clients Python `websockets` 16.1 (régies et spectateurs), Playwright 1.63 pilotant Microsoft Edge (interface), psutil + `nvidia-smi` (ressources)

Modèles (d'après `config.yaml` , tous déjà dans le cache Hugging Face) :

Étape	Modèle	Matériel réellement utilisé
Transcription	Whisper `large-v3-turbo` , `beam_size: 5` , `min_chunk_s: 1.0`	**CPU en int8.** Le chargement sur GPU a échoué avec `cublas64_12.dll is not found` , et le repli automatique de l'application a pris le relais
Segmentation	SaT `sat-3l-sm` , moteur ONNX	CPU
Traduction	Marian `opus-mt-{src}-{tgt}` , pools `per_session` , `en-fr` et `fr-en` chargées au démarrage	CPU

Étape	Modèle	Matériel réellement utilisé
Voix	`tts.engine: browser` (valeur par défaut). Piper testé à part avec `en_US-lessac-medium`, `de_DE-thorsten-medium`, `fr_FR-siwis-medium`	Navigateur / CPU

Réglages de l'événement : `max_sessions: 3`, `whisper_workers: 3`, `marian_instances: per_session`, `sat_parallel: true`, `cpu.torch_threads: 4`.

Lancement de l'application. Un script lanceur a démarré l'application, sans modification, avec uvicorn sur le port **8010**, car le port 8000 était pris par `whisper_service.py`. Il a appliqué deux réglages propres aux tests : les journaux des tests ont été redirigés vers un dossier temporaire, pour laisser propre le dossier `runs/` du projet, et le scénario Piper a mis `tts.engine: piper`. Pour le scénario de panne, le même lanceur peut faire lever une exception à SaT dans **une seule salle nommée**, activée et désactivée à chaud par un fichier-drapeau. Aucun fichier de l'application n'a été modifié.

Audio de test. Trois conférences en vraie parole synthétique, générées avec Piper, 16 kHz mono, envoyées en temps réel par blocs PCM de 100 ms, exactement comme le fait le navigateur. Chaque conférence a son propre sujet, pour qu'une fuite entre sessions se voie sous forme de mot-clé étranger :

Conférence	Langue	Durée	Mots-clés servant à détecter une fuite
A	Allemand	25,7 s	München / Munich, Solaranlagen / solaire, Schulen / écoles, Batterie
B	Anglais	26,5 s	hospitals, pneumonia, x-rays, neural networks
C	Français	25,0 s	Bordeaux, vignobles / vineyards, abeilles / bees, agriculteurs

Scénarios, étape par étape

Chaque scénario a piloté le vrai serveur par son WebSocket ou par ses pages. L'audio a toujours été envoyé en temps réel. Les tableaux comparent le comportement attendu avec ce qui a été mesuré.

S1 — Une session : démarrer, arrêter, redémarrer

1. Une régie `e2e-solo` (participant `regie-solo`) et un spectateur se sont connectés.

2. Démarrage allemand → anglais + français, voix activée. La conférence allemande (25,7 s) a été envoyée, puis **Arrêter**.
3. Une fois le test enregistré, redémarrage sur la même connexion : français → anglais + allemand, conférence française, puis Arrêter.
4. Les deux connexions ont été fermées.

Vérification	Attendu	Constaté	Résultat
Message `hello`	salle, `session_id`, état, participant	`e2e-solo`, état `created`, participant renvoyé	RÉUSSI
État après Démarrer / Arrêter	`running` / `stopping`, puis `stopped`	Exactement cela	RÉUSSI
Transcription	Proche de la référence	WER 5,7 % (DE), 0 % (FR)	RÉUSSI
Traductions	6 phrases définitives par langue cible	12 par passage, sens correct en EN, FR et DE	RÉUSSI
Messages de voix	Un `speak` par phrase, dans la première langue cible	6 par passage, en anglais	RÉUSSI
Spectateur	Mêmes phrases que la régie	Identiques	RÉUSSI
Redémarrage	Second passage complet	Complet, état `stopped` à la fin	RÉUSSI
Après la déconnexion	Place libérée, plus de régie	`slot: null`, `producer: false`	RÉUSSI
Retard	Sous-titres quelques secondes après la parole	**22 à 25 s** en médiane (Whisper sur CPU)	ÉCHOUÉ (voir Performances)

S2 et S3 — Deux, puis trois sessions simultanées

1. Salles `e2e-amphi-a` (allemand → EN, FR), `-b` (anglais → DE, FR) et `-c` (français → EN, DE). Chacune avait une régie et 2 spectateurs avec un `participant_id`.
2. Toutes les salles ont démarré ensemble, et toutes les conférences ont été envoyées en même temps.

3. S3 seulement : pendant que 3 salles tournaient, une 4e régie `e2e-amphi-d` a cliqué sur Démarrer.
4. À 10 s, le spectateur 2 de chaque salle est parti. Il est revenu à 18 s.
5. Arrêt dans chaque salle, puis attente de l'enregistrement de chaque test.

Vérification	Attendu	Constaté	Résultat
Toutes les salles en `running`	Oui	2/2 et 3/3	RÉUSSI
4e salle	Refusée avec un message clair	« Capacité atteinte : 3 sessions déjà en cours (e2e-amphi-a, …) » ; la salle reste `created`	RÉUSSI
Participants	3 par salle (régie + 2 spectateurs)	Exactement ces identifiants ; 2 après le départ	RÉUSSI
Spectateur parti puis revenu	De retour dans la liste, reçoit les sous-titres en direct	De retour ; a reçu les 6 phrases	RÉUSSI
Transcription par salle	Chaque salle reçoit son propre texte	WER 3,8 / 6,2 % (S2) ; 5,7 / 6,2 / 1,7 % (S3)	RÉUSSI
Isolation	Aucun mot-clé étranger dans aucun message d'aucune salle	Aucun (régies et spectateurs)	RÉUSSI
Diffusion	Spectateur 1 = régie	Phrases et traductions définitives identiques dans chaque salle	RÉUSSI
État final	Toutes `stopped`, aucune place occupée	Oui	RÉUSSI

S4 — Arrêter une salle sur trois, puis la redémarrer

1. Trois salles comme dans S3.
2. La salle B a envoyé 10 s puis s'est arrêtée, pendant que A et C continuaient.
3. Une fois B enregistrée, B a redémarré sur la même connexion et envoyé toute sa conférence.

Vérification	Attendu	Constaté	Résultat
B après Arrêter	`stopping`, puis `stopped`, place libérée	Oui. `stopping` a duré environ 39 s, le temps de transcrire sur CPU l'audio en attente	RÉUSSI
A et C	Non affectées, texte complet	WER 5,7 % et 1,7 %, aucune erreur	RÉUSSI
Redémarrage de B	`running`, second passage complet	WER 6,2 %, traductions vers DE et FR	RÉUSSI
Fuites	Aucune	Aucune	RÉUSSI

S5 — Panne dans une salle

1. Une panne de SaT a été injectée pour la salle A seulement, dès le début.
2. Les salles A, B et C ont démarré et envoyé leurs conférences.
3. Quand A est tombée en panne, une nouvelle salle D a tenté de démarrer.
4. B et C se sont arrêtées normalement.
5. La panne a été retirée, et A a redémarré depuis la même régie.

Vérification	Attendu	Constaté	Résultat
État de A	`error`, place libérée	`error` (« segmentation : RuntimeError … »), `slot: null`	RÉUSSI
Régie de A prévenue	Message d'erreur grave, connexion maintenue	`{"type":"error","fatal":true,"where":"segmentation"}` ; WebSocket ouvert ; test enregistré comme interrompu	RÉUSSI
Journal du serveur	Trace complète	Trace, puis `running → error`	RÉUSSI
B et C	Continuent jusqu'au bout	`running` au moment de la panne ; WER 6,2 % et 1,7 % ; aucune erreur	RÉUSSI
Place libérée	Utilisable par une autre salle	La salle D a démarré	RÉUSSI
Redémarrage de A	Fonctionne une fois la panne retirée	`running`, puis `stopped`, WER 5,7 %	RÉUSSI

S6 — Connexion WebSocket, reconnexion et cas limites

Étape	Attendu	Constaté	Résultat
Régie et spectateur via `/ws/session/e2e-ws`	Comme `/ws?room=`	`session_id: e2e-ws`, rôles corrects	RÉUSSI
Seconde régie sur la même salle	Refusée	Erreur `where: room`, connexion fermée par le serveur	RÉUSSI
Commande JSON mal formée	Erreur renvoyée, connexion maintenue	`JSONDecodeError …` renvoyé ; toujours ouverte	RÉUSSI
À 12 s, langues cibles EN → FR et `th_high` passé à 0,6	Pris en compte ; phrases suivantes en français	Les deux confirmés ; les 6 phrases définitives en français ; le spectateur a reçu le changement	RÉUSSI
Coupure TCP de la régie pendant une session	Session fermée, place libérée	`stopped`, place libérée en moins de 3 s ; le spectateur reste connecté et reçoit `run_saved`	RÉUSSI
La régie se reconnecte à la même salle	Acceptée	`hello`, nouvelle session démarrée	RÉUSSI
Trame audio de 3 octets (taille impaire)	Trame rejetée, la session continue	**Connexion fermée et session terminée.** Journal du serveur : `buffer size must be a multiple of element size`. Aucune erreur envoyée	ÉCHOUÉ
URL de spectateur pour une salle inconnue	Idéalement, pas de salle permanente	Salle créée ; supprimable via `DELETE /api/rooms/{nom}` (200)	RÉUSSI (remarque)
Suppression d'une salle inconnue	404	409 avec « Salle inconnue »	RÉUSSI (mineur)

UI-1 à UI-7 — Vraies pages dans Microsoft Edge

1. Ouverture de `/event`. Ouverture de la régie `/?room=ui-a` en mode **fichier** avec la conférence allemande, allemand → EN + FR.
2. Dans une seconde instance d'Edge avec un micro simulé qui lit la conférence anglaise, ouverture de la régie `/?room=ui-b` en mode **micro**, anglais → FR.
3. Ouverture de `/viewer?room=ui-a&lang=en` et `/viewer?room=ui-b&lang=fr`, puis clic sur Démarrer dans les deux régies.
4. Changement de langue sur l'écran public, puis passage de cet écran à l'autre salle.
5. Ouverture d'une seconde régie pour `ui-a`.
6. Injection d'une panne dans `ui-a`, puis nouveau démarrage.
7. Création puis suppression d'une salle vide depuis le tableau de bord.

Vérification	Attendu	Constaté	Résultat
Tableau de bord	3 places, capacité en direct	« 0 / 3 », puis « 2 / 3 sessions en cours » ; les deux salles « En cours »	RÉUSSI
Régie, mode fichier	État en direct, sous-titres, traductions, test enregistré	« En direct : allemand, sous-titres en anglais et français » ; 6 phrases + EN/FR ; « Test enregistré »	RÉUSSI
Boutons	Démarrer désactivé et Arrêter actif pendant la session ; l'inverse à la fin	Oui	RÉUSSI
Voix du navigateur	Une énonciation par phrase définitive	6 × `en-US` (salle ui-a) ; 6 × `fr-FR` (salle ui-b)	RÉUSSI
Régie, mode micro	Fonctionne comme le mode fichier	Fonctionne ; texte sans ponctuation ni majuscules, et les deux premières phrases fusionnées en une	RÉUSSI (remarque)

Vérification	Attendu	Constaté	Résultat
Changement de langue et de salle sur l'écran public	Les lignes changent de langue ; le changement de salle affiche cette salle	Oui ; titre « Sous-titres · ui-b », URL mise à jour	RÉUSSI
Seconde régie	Refusée, Démarrer désactivé	« Une régie est déjà connectée … », Démarrer désactivé	RÉUSSI
Panne vue dans l'interface	La régie affiche l'erreur et peut relancer ; l'écran public affiche une interruption ; le tableau de bord affiche « Erreur »	Régie et tableau de bord corrects ; **l'écran public affiche « Session terminée »**	ÉCHOUÉ (écran public)
Suppression d'une salle	Deux clics ; seules les salles au repos sont supprimables	« Confirmer la suppression », salle retirée ; les salles occupées n'ont pas de bouton Supprimer	RÉUSSI
Erreurs dans la console du navigateur	Aucune	Aucune	RÉUSSI

UI-8 — Coupure et redémarrage du serveur

1. Avec une régie et un écran public ouverts sur la salle `rc-a`, le processus du serveur a été tué.
2. Après 3 s, les pages ont été vérifiées. Le serveur a ensuite été relancé et était de retour après 24,8 s.

Vérification	Attendu	Constaté	Résultat
Pendant la coupure	Les deux pages signalent la coupure	Régie : « Serveur déconnecté. Relance le serveur puis recharge la page. » Écran public : « Reconnexion… »	RÉUSSI
Après le redémarrage : écran public	Se reconnecte seul	« En attente du début », de nouveau compté par le serveur	RÉUSSI

Vérification	Attendu	Constaté	Résultat
Après le redémarrage : régie	Se reconnecte seule	Reste déconnectée jusqu'à un rechargement manuel	ÉCHOUÉ

TTS — Navigateur et Piper

1. **Voix du navigateur :** voir S1–S3 et UI-2/3. Les messages `speak` partent vers la salle ; la page de la régie les prononce.
2. **Piper, 3 salles (TTS-P3) :** serveur redémarré avec `tts.engine: piper`. Les salles ont démarré à 12 s d'intervalle pour éviter le défaut de chargement Marian. Voix en mode Auto.
3. **Piper dans le navigateur (TTS-P2) :** la page de la régie a reçu les WAV de Piper et les a décodés (`decodeAudioData` appelé 6 fois).
4. **Voix absente :** avec un mauvais dossier de voix, chaque phrase a renvoyé « Voix Piper introuvable … Télécharge-la avec : … ». Sous-titres et traductions n'ont pas été affectés.

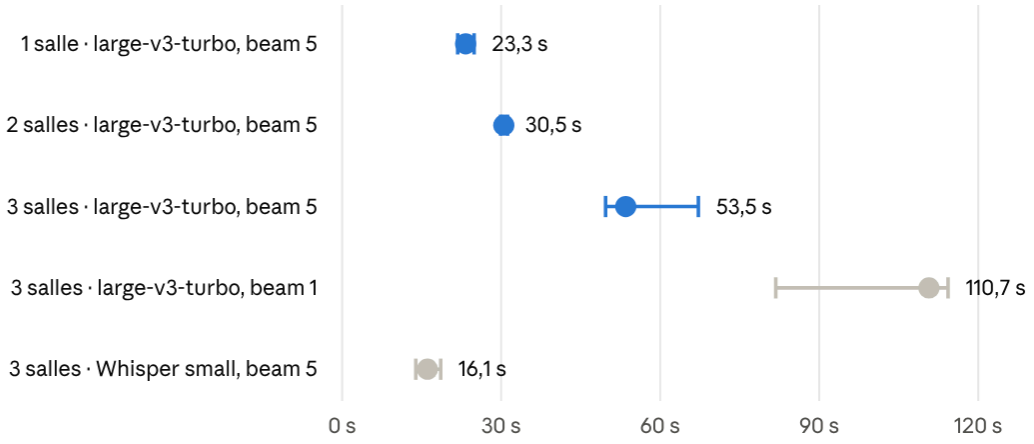
Vérification	Attendu	Constaté	Résultat
Sortie de Piper	Un WAV par phrase définitive, dans la bonne langue	18 WAV : 6 EN, 6 DE, 6 EN ; de 1,4 à 5,6 s de parole chacun	RÉUSSI
Temps de synthèse	Bien inférieur à la durée de la phrase	0,1 à 0,4 s par phrase ; 2,0 à 3,4 s pour la première phrase de chaque voix (chargement de la voix)	RÉUSSI
Synthèse en parallèle entre salles	—	Aucune synthèse simultanée sur 30, ce qui concorde avec le verrou global unique de Piper	Remarque

Performances

Aucune configuration testée ne donne de sous-titres en direct sur cette machine. Whisper sur CPU est le goulot d'étranglement : chaque salle de plus ajoute du retard, tandis que SaT et Marian restent légers.

Sur CPU, le retard médian passe de 23 s (1 salle) à 54 s (3 salles)

Secondes entre la fin d'une phrase et son sous-titre · point = médiane, barre = salle la plus rapide à la plus lente



Bleu = configuration réelle de config.yaml (Whisper sur CPU après le repli). Gris = variantes testées pour comparaison.

Exécutions E2E S1, S2, S3, S3 en beam 1, S3 avec Whisper small · messages enregistrés par les clients de test, 5 oct. 2026

Le retard est mesuré entre la fin de la phrase prononcée et l'arrivée de son sous-titre, avec un audio envoyé en temps réel. Les traductions définitives arrivent 1,5 à 6 s après le sous-titre.

Configuration	Passe Whisper (médiane)	Marian, phrase définitive	SaT	CPU du serveur, moyen / pic (1 600 % = 16 threads)	RAM du serveur, pic	Threads
1 salle, large-v3-turbo, beam 5	9,7 s	0,39 s	13 ms	432 % / 680 %	4,3 Go	91
2 salles, large-v3-turbo, beam 5	16,5 s	0,76 s	16 ms	792 % / 1 032 %	5,2 Go	96
3 salles, large-v3-turbo, beam 5	23,2 s	0,96 s	17 ms	1 122 % / 1 334 %	6,0 Go	104
3 salles, large-v3-turbo, beam 1	40,2 s	3,9 s	154 ms	687 % / 1 367 %	4,8 Go	110
3 salles, Whisper small, beam 5	4,8 s	1,15 s	12 ms	1 273 % / 1 511 %	4,9 Go	135

- **VRAM :** 2,6 Go occupés pendant toutes les exécutions, entièrement par l'autre programme. L'application n'a utilisé aucune mémoire GPU, puisque Whisper tournait sur CPU.
- **`beam_size: 1` n'aide pas sur CPU.** Un nouvel essai avec une seule salle a donné 10,6 à 13,6 s par passe Whisper, contre 9 à 10 s en beam 5. L'essai lent à 3 salles en beam 1 a aussi subi l'échec de chargement Marian (P1) : il s'agit d'une seule exécution, non concluante.

- **Mémoire sur environ 1 heure, sur un même serveur :** le pic est passé de 3,2 Go à 6,0 Go à mesure que chaque place chargeait ses propres paires Marian, puis s'est stabilisé. Aucune fuite n'a été observée, mais aucun test d'endurance n'a été fait.
- **Voix Piper :** 0,1 à 0,4 s par phrase, négligeable à côté du retard de Whisper.
- **Démarrage :** modèles prêts en 30 à 35 s depuis le cache. Le premier téléchargement de Whisper `small` a pris 189 s.

Problèmes trouvés

Neuf problèmes ont été trouvés : un critique, un de gravité élevée, deux moyens, cinq faibles. Aucun n'a été corrigé, comme demandé.

ID	Problème	Gravité	Preuve	Cause probable
P1	**Quand des modèles Marian se chargent en même temps, tous les chargements suivants échouent.** Les paires de langues touchées ne sont plus traduites jusqu'au redémarrage du serveur. La régie voit seulement « Aucun modèle pour en -> de » à chaque phrase, et le tableau de bord n'affiche rien.	Critique	`server_piper.log` : `Paire en -> fr indisponible (Cannot copy out of meta tensor …)` à 17:47:52, puis en→de et fr→de ont aussi échoué en étant chargées seules. `server_beam1.log` : 6 échecs lors d'un démarrage simultané de 3 salles. `repro_meta.py`, hors de l'application : 6 chargements en parallèle ont échoué lors de 2 essais sur 3, et un chargement seul fait ensuite a aussi échoué ; 6 chargements séquentiels ont réussi 6 fois sur 6. Non observé sur les 4 autres démarrages du serveur.	`from_pretrained` de `transformers` 5.8 n'est pas sûr entre threads (initialisation sur le périphérique « meta », imports différés). L'application charge des modèles depuis plusieurs threads à la fois : un pool Marian par place quand des salles démarrent ensemble, plus le thread `_preload` et le thread de traduction de chaque session. Une paire en échec est mémorisée définitivement dans `MarianPool.missing`.
P2	**Les sous-titres ne sont pas en temps réel avec la configuration réelle.** Le retard médian est de 23 s avec 1 salle et de 54 s avec 3 salles.	Élevée	Voir Performances. Journal de démarrage : `Whisper ne peut pas utiliser le GPU (Library cublas64_12.dll is not found …). Repli sur CPU int8`.	Les bibliothèques CUDA 12 cuBLAS et cuDNN manquent, donc `large-v3-turbo` tourne sur CPU. Chaque passe retranscrit jusqu'à 15 s de tampon, et 3 salles se partagent 16 threads (CPU à 1 100–1 270 %).

ID	Problème	Gravité	Preuve	Cause probable
P3	**Une seule trame audio invalide (nombre d'octets impair) ferme la connexion de la régie et met fin à sa session.** Aucune erreur n'est affichée, et la salle finit en `stopped`, pas en `error`.	Moyenne	S6 : une trame de 3 octets a fermé le WebSocket. Journal du serveur : `WebSocket fermé : buffer size must be a multiple of element size`.	`pcm16_to_float` (`np.frombuffer`) lève une exception dans la boucle de réception du WebSocket. Le gestionnaire générique ferme alors la connexion et la session.
P4	**Les tuiles de retard de la régie sont trompeuses.** « Retard des mots » affichait 1,9 s alors que le retard réel était d'environ 22 s, et la tuile indique « Whisper, GPU (ms) » alors que Whisper tourne sur CPU.	Moyenne	Capture `ui2_regie_file_de_end.png` comparée aux mesures de S1.	L'indicateur vaut « audio reçu − dernier mot validé » en temps audio, ce qui ignore le retard de calcul. Le libellé GPU est un texte fixe.
P5	**La régie ne se reconnecte pas seule après une coupure du serveur.** L'écran public, lui, se reconnecte.	Faible	UI-8 : la régie est restée sur « Serveur déconnecté … » jusqu'à son rechargement ; l'écran public s'est reconnecté environ 4 s après le retour du serveur.	Seul `viewer.html` a une boucle de reconnexion.
P6	**Après une panne de session, l'écran public affiche « Session terminée »** au lieu d'un message d'interruption.	Faible	UI-6, `ui6_viewer_interruption.png`	Dans `viewer.html`, le message `run_saved` qui suit l'erreur remplace l'état affiché.

ID	Problème	Gravité	Preuve	Cause probable
P7	**En mode micro, la transcription perd la ponctuation et les majuscules,** et deux phrases ont été fusionnées en une. Le mode fichier était correct.	Faible	Liste des phrases de UI-3 et `ui3_regie_mic_en_end.png`	Probablement l'annulation d'écho et la réduction de bruit du navigateur, appliquées au micro simulé, qui modifient le signal. À vérifier avec un vrai micro.
P8	**Une salle arrêtée peut rester en `stopping` jusqu'à environ 39 s,** et garde sa place pendant ce temps.	Faible	Transitions de S4	Le retard accumulé de P2 doit être transcrit avant que la place soit libérée.
P9	N'importe quelle URL de spectateur crée une salle qui reste jusqu'à sa suppression. Supprimer une salle inconnue renvoie 409 au lieu de 404.	Faible	S6	`RoomManager.get` crée les salles à la demande.

Preuves

Toutes les preuves sont copiées dans `C:\Users\Administrator\Downloads\fichiers-multisession-e2e-evidence\` (7,2 Mo). Les scripts de test y sont aussi, pour pouvoir rejouer chaque scénario.

Dossier ou fichier	Contenu
`shots/`	15 captures d'écran d'Edge : `ui1_event_idle`, `ui1_event_two_rooms_running`, `ui2_regie_file_de_end`, `ui3_regie_mic_en_end`, `ui4_viewer_a_en`, `ui4_viewer_b_fr`, `ui4_viewer_switched_to_b`, `ui5_second_regie_refused`, `ui6_regie_fatal_error`, `ui6_viewer_interruption`, `ui6_event_error_state`, `ui8_regie_server_down`, `ui8_viewer_reconnecting`, `ui8_viewer_reconnected`, `tts_p2_regie_piper`
`logs/<scénario>.json`	Résultats mesurés par scénario : états, transitions, WER, retards, fuites, ressources (`s1`, `s2`, `s3`, `s4`, `s5`, `s6`, `ui`, `reconnect_piper`, `piper2`, `piper_missing_voice`, `s3_beam1`, `s1_beam1`, `s3_small`)
`logs/<scénario>_messages.jsonl`	Chaque message WebSocket reçu par chaque client, avec son horodatage
`logs/server_*.log`	Journaux complets des 6 démarrages du serveur (`browser`, `piper`, `piper2`, `piper3`, `beam1`, `small`)
`runs/`	Les dossiers de test de l'application elle-même (`meta.json`, `events.jsonl`, `segments.csv`, `summary.json`) pour chaque session de test, plus `journal_des_tests.jsonl`
`audio/`	Les trois conférences de test (WAV) et leurs phrases de référence (`meta.json`)
`run_server.py`, `e2e_lib.py`, `s*.py`, `ui*.py`, `repro_meta.py`	Le lanceur et les scripts de test. `repro_meta.py` reproduit P1 sans l'application

Lignes clés des journaux :

```
17:28:06 asr  Whisper ne peut pas utiliser le GPU (Library cublas64_12.dll is
not found or cannot be loaded). Repli sur CPU int8
17:37:36 seg  Segmentation arrêtée par une erreur (segmenter-worker-e2e-
amphi-a:main)
17:37:36 rooms Salle « e2e-amphi-a » : running → error (segmentation :
RuntimeError: E2E fault injection …)
17:42:09 server WebSocket fermé : buffer size must be a multiple of element
size
17:47:52 mt   Paire en -> fr indisponible (Cannot copy out of meta tensor; no
data! …)
17:54:01 mt   Paire fr -> de indisponible (Cannot copy out of meta tensor; no
data! …)
```

Recommandations et priorité des corrections

Corriger P1 et faire tourner Whisper sur un GPU avant tout événement en direct ; le reste peut suivre.

Priorité	Action	Corrige	Effort
1 — avant tout événement	Charger les modèles Marian **un par un** : un verrou unique pour tout le processus autour de la création de `MarianTranslator` dans `MarianPool.get`. Ne pas mémoriser une paire dans `missing` après une exception inattendue (réessayer plus tard), et signaler une paire en échec à la régie et au tableau de bord. Éventuellement, figer `transformers` sur une version validée avec ce code.	P1	Faible

Priorité	Action	Corrige	Effort
1 — avant tout événement	Faire tourner Whisper sur un GPU. Installer `nvidia-cublas-cu12` et `nvidia-cudnn-cu12==9.*` (README, section Windows), donner à l'application un GPU qu'elle ne partage pas (les 4 Go de la RTX 2050 étaient surtout occupés par un autre programme), puis rejouer S1–S3 et vérifier un retard de quelques secondes. Sans GPU, utiliser `asr.model: small` et compter environ 16 s de retard avec 3 salles.	P2, P8	Installation simple, matériel nécessaire
2	Valider les trames audio avant de les décoder (taille paire, en-tête attendu), et ignorer une trame invalide avec un avertissement au lieu de fermer la connexion.	P3	Faible
2	Afficher le retard réel dans la régie (heure réelle moins le temps audio du mot), et afficher le matériel réellement utilisé par Whisper (`info.whisper.device`).	P4	Faible
3	Ajouter la reconnexion automatique à la régie, comme sur l'écran public. Conserver les réglages de la salle et proposer de relancer la session.	P5	Moyen
3	Sur l'écran public, garder le message d'interruption quand une erreur arrive avant `run_saved` .	P6	Faible
3	Vérifier le mode micro avec un vrai micro. Si la ponctuation manque toujours, essayer `echoCancellation` et `noiseSuppression` à false.	P7	Faible
4	Ne créer une salle que depuis une régie (ou le tableau de bord). Renvoyer 404 pour une salle inconnue sur `DELETE` .	P9	Faible

À retester après les corrections : S2/S3 avec démarrages simultanés, répétés 5 fois sans aucune ligne « indisponible » (P1) ; S1–S3 sur GPU (P2) ; la trame invalide de S6 (P3) ; UI-6 et UI-8 (P5, P6).

Pas encore couvert, à tester avant un vrai événement : un vrai micro sur un autre ordinateur en HTTPS, le mode panel avec plusieurs micros, une centaine de spectateurs par salle, un test d'endurance de plusieurs heures en surveillant la mémoire, et la campagne de tests pendant des sessions en direct.